Table of Contents

Table of Contents 0
基因组survey报告 1
1 概述 1
2 实验方法 1
3 Survey 分析流程 1
4 测序数据产出及质控 1
4.1 数据说明 1
4.1.1 原始测序数据 1
4.1.2 Clean Data 2
4.2 数据过滤方法 2
4.3 质控结果 2
4.3.1 测序数据统计 2
4.3.2 测序质量评估 2
4.3.3 NT比对情况统计 3
4.4 质控小结 3
5 K-mer分析 3
5.1 K-mer 分析原理 3
5.1.1 基因组大小预估 3
5.1.2 杂合率和重复序列预估 4
5.2 K-mer 分析结果 4
6 结论 5
7 软件版本 5
8 参考文献 5

[redacted]

基因组survey报告

合同信息	合同内容
项目编号	ZY20251029-XM51332
项目名称	survey
物种名称	Nymphaea lotus
物种倍性	•
客户预估基因组大小	
测序平台	BGI
survey预估基因组大小	1713.74M
survey预估基因组杂合度	0.24%
survey预估基因组重复率	74.14%

1 概述

基因组survey以测序技术为基础，基于小片段文库的低深度测序，通过K-mer分析，快速获得基因组大小、杂合度、重复序列比例等基本信息，为制定该物种的全基因组de novo测序策略提供有效依据。

2 实验方法

检测合格的DNA样本通过Covaris超声波破碎仪随机打断成长度为300-500bp的片段，经末端修复、加A尾、加测序接头、纯化、PCR扩增等步骤完成整个文库制备。构建好的文库进行二代PE测序。

3 Survey 分析流程

基因组survey分析流程主要包括：数据质控、NT比对、K-mer分析等步骤，得到clean数据、评估数据的污染情况、预估基因组大小、杂合度、重复率等信息。

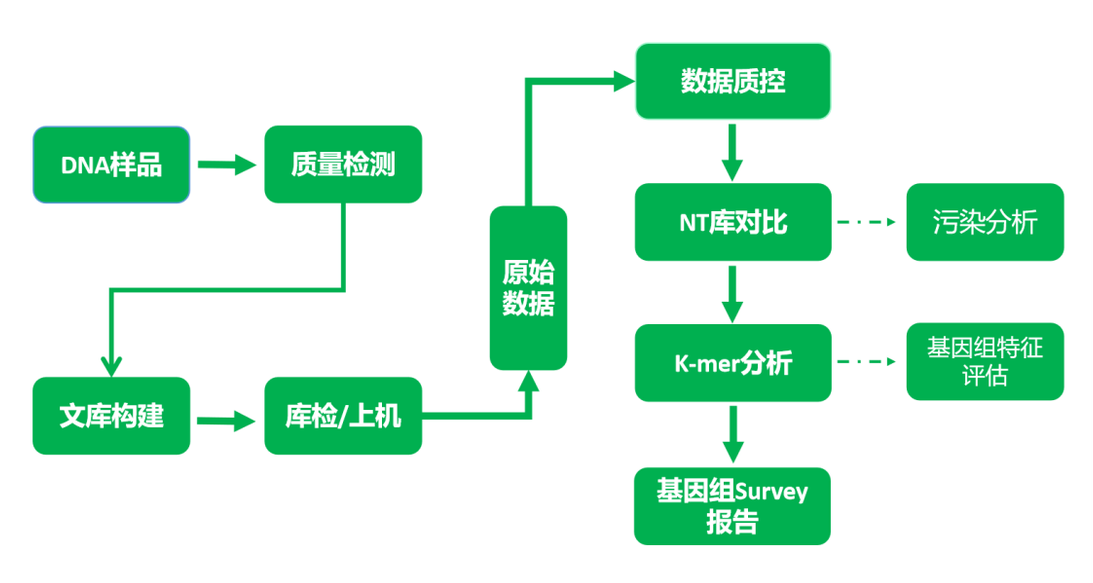

Survey分析流程图

4 测序数据产出及质控

检测合格的DNA样本通过Covaris超声波破碎仪随机打断成长度为300-500bp的片段，经末端修复、加A尾、加测序接头、纯化、PCR扩增等步骤完成整个文库制备。构建好的文库通过Illumina NovaSeq或BGI MGISEQ进行PE150测序。

测序数据的产生经过了DNA提取、建库、测序多个步骤的，然而，这些步骤中产生的无效数据会对生物信息数据高级分析带来严重的干扰，比如建库阶段会出现建库长度的偏差，测序阶段会出现测序错误的情况。我们必须通过一些手段将这些无效数据过滤排除掉，以保证生物信息分析的正常进行。

4.1 数据说明

4.1.1 原始测序数据

高通量测序 (如BGI的MGIseq2000等一系列的测序平台) 测序得到的原始图像数据文件经碱基识别 (Base Calling) 分析转化为原始测序序列 (Sequenced Reads) ，我们称之为 Raw Data 或 Raw Reads，结果以 FASTQ (简称为 fq) 文件格式存储，其中包含测序序列 (reads) 的序列信息以及其对应的测序质量信息。测序样本中真实数据随机截取结果如下：

```
@V300028317L4C001R0020001525/1
GTCTGCGTCTGCATTCTGCGTTCAGCGTCTGCGTCCTGCG
+
FFF?FFGFGFGFFFFF?GFFFFFAFFG=FFGGGFFFGFFG
```

每个序列共有 4 行信息：

第 1 行是序列名称，由测序仪产生，包含index序列及read1或read2标志；

第 2 行是序列，由大写“ACGTN”组成；

第 3 行是序列ID，也有省略了ID名称后直接用“+”表示；

第 4 行是序列的测序质量，每个字母对应第 2 行每个碱基；

测序碱基质量值的表示方法：

碱基的质量都是以ASCII值表示的，根据测序时采用的质量方案的不同，计算十进制的质量值的方法也有所区别，常见的计算方法如下所示：

（1）质量值 = 字符的ASCII值 - 64

（2）质量值 = 字符的ASCII值 - 33

测序碱基质量值的范围是[0,40]，即ASCII值表示为[B,h] 或 [#,I]。

测序错误率与测序质量值简明对应关系。具体地，如果测序错误率用 E 表示，碱基质量值用 Q 表示，则有如下关系 ： Q = -10 log10(E)。

4.1.2 Clean Data

原始测序数据中会包含接头信息，低质量碱基，未测出的碱基 (以N表示) ，这些信息会对后续的信息分析造成很大的干扰，通过精细的过滤方法将这些干扰信息去除掉，最终得到的数据即为有效数据，我们称之为clean data 或 clean reads，该文件的数据格式与Raw data完全一样。

4.2 数据过滤方法

测序得到的原始序列，可能带有接头和低质量的reads。为了保证信息分析质量，首先需要对Raw reads进行过滤，得到Clean reads，后续分析基于Clean reads进行。我们采用SOAPnuke软件对Raw reads进行过滤，得到Clean reads，主要参数：–lowQual=20，–nRate=0.005，–qualRate=0.5，其他参数默认。数据处理的步骤如下：

1）过滤掉含有接头序列的reads；

2）去除由于PCR扩增等原因引起的duplicated reads；

3）当单端测序read中的一端含有的N的含量超过该条read长度比例的 10% 时，需要去除此对paired reads；

4）当单端测序read中的一端含有的低质量 (<=5) 碱基数超过该条read长度比例的 50% 时，需要去除此对paired reads。

4.3 质控结果

4.3.1 测序数据统计

完成建库并上机测序了1个样本的文库。采用BGI测序平台进行双末端测序，测序结果详见下表

样本survey 数据统计

data type	SampleName	ReadNum	BaseCount(bp)	ReadLength(bp)	Q20(%)	Q30(%)	GC Content(%)
raw data	Nymphaea_lotus	748769458	112315418700	150;150	99.3;98.8	97.6;96.7	37.7;37.7
clean data	Nymphaea_lotus	720935564	108140334600	150;150	99.3;98.8	97.7;96.7	37.5;37.5

说明：

1. data type：raw data原始数据，clean data质控后数据；
2. SampleName：样品名称；
3. ReadNum：测序reads序列数目；
4. BaseCount(bp)：测序数据的总碱基数；
5. ReadLength(bp)：测序数据平均长度；
6. Q20(%)：Phred数值大于20的碱基占总体碱基的百分比；
7. Q30(%)：Phred数值大于30的碱基占总体碱基的百分比；
8. GC Content(%)：碱基G和C的数量占总的碱基数量的百分比。

4.3.2 测序质量评估

使用FastQC软件，从以下四方面对测序质量进行评估：

1）测序数据质量检查：测序的质量应该主要分布在Q20以上，这样才能保证后续高级分析的正常进行。

2）测序错误率分布检查: 根据测序技术的特点，测序片段末端的碱基质量一般会比前端的低。测序错误率与碱基质量有关，根据测序技术的特点，测序片段末端的错误率会偏高，并且大片段文库测序的错误率比小片段文库测序的错误率高。

3）碱基频率分布检查：用于检测有无AT、GC分离现象。统计测序碱基A、T、C、G、N的含量分布，根据碱基互补原则，A和T的比例应该接近，C和G的比例也应该是接近的。而N含量也反映了测序质量的好坏。

4）GC含量分布检查：通常GC含量应该呈现单峰，如果存在多峰，可能由外源基因组污染引起。

下面分别为各个文库reads各位置碱基组成、碱基错误率、GC含量信息。其中上图为双端测序序列的第一端测序reads的质量分布情况，下图为另一端测序reads的质量分布情况。

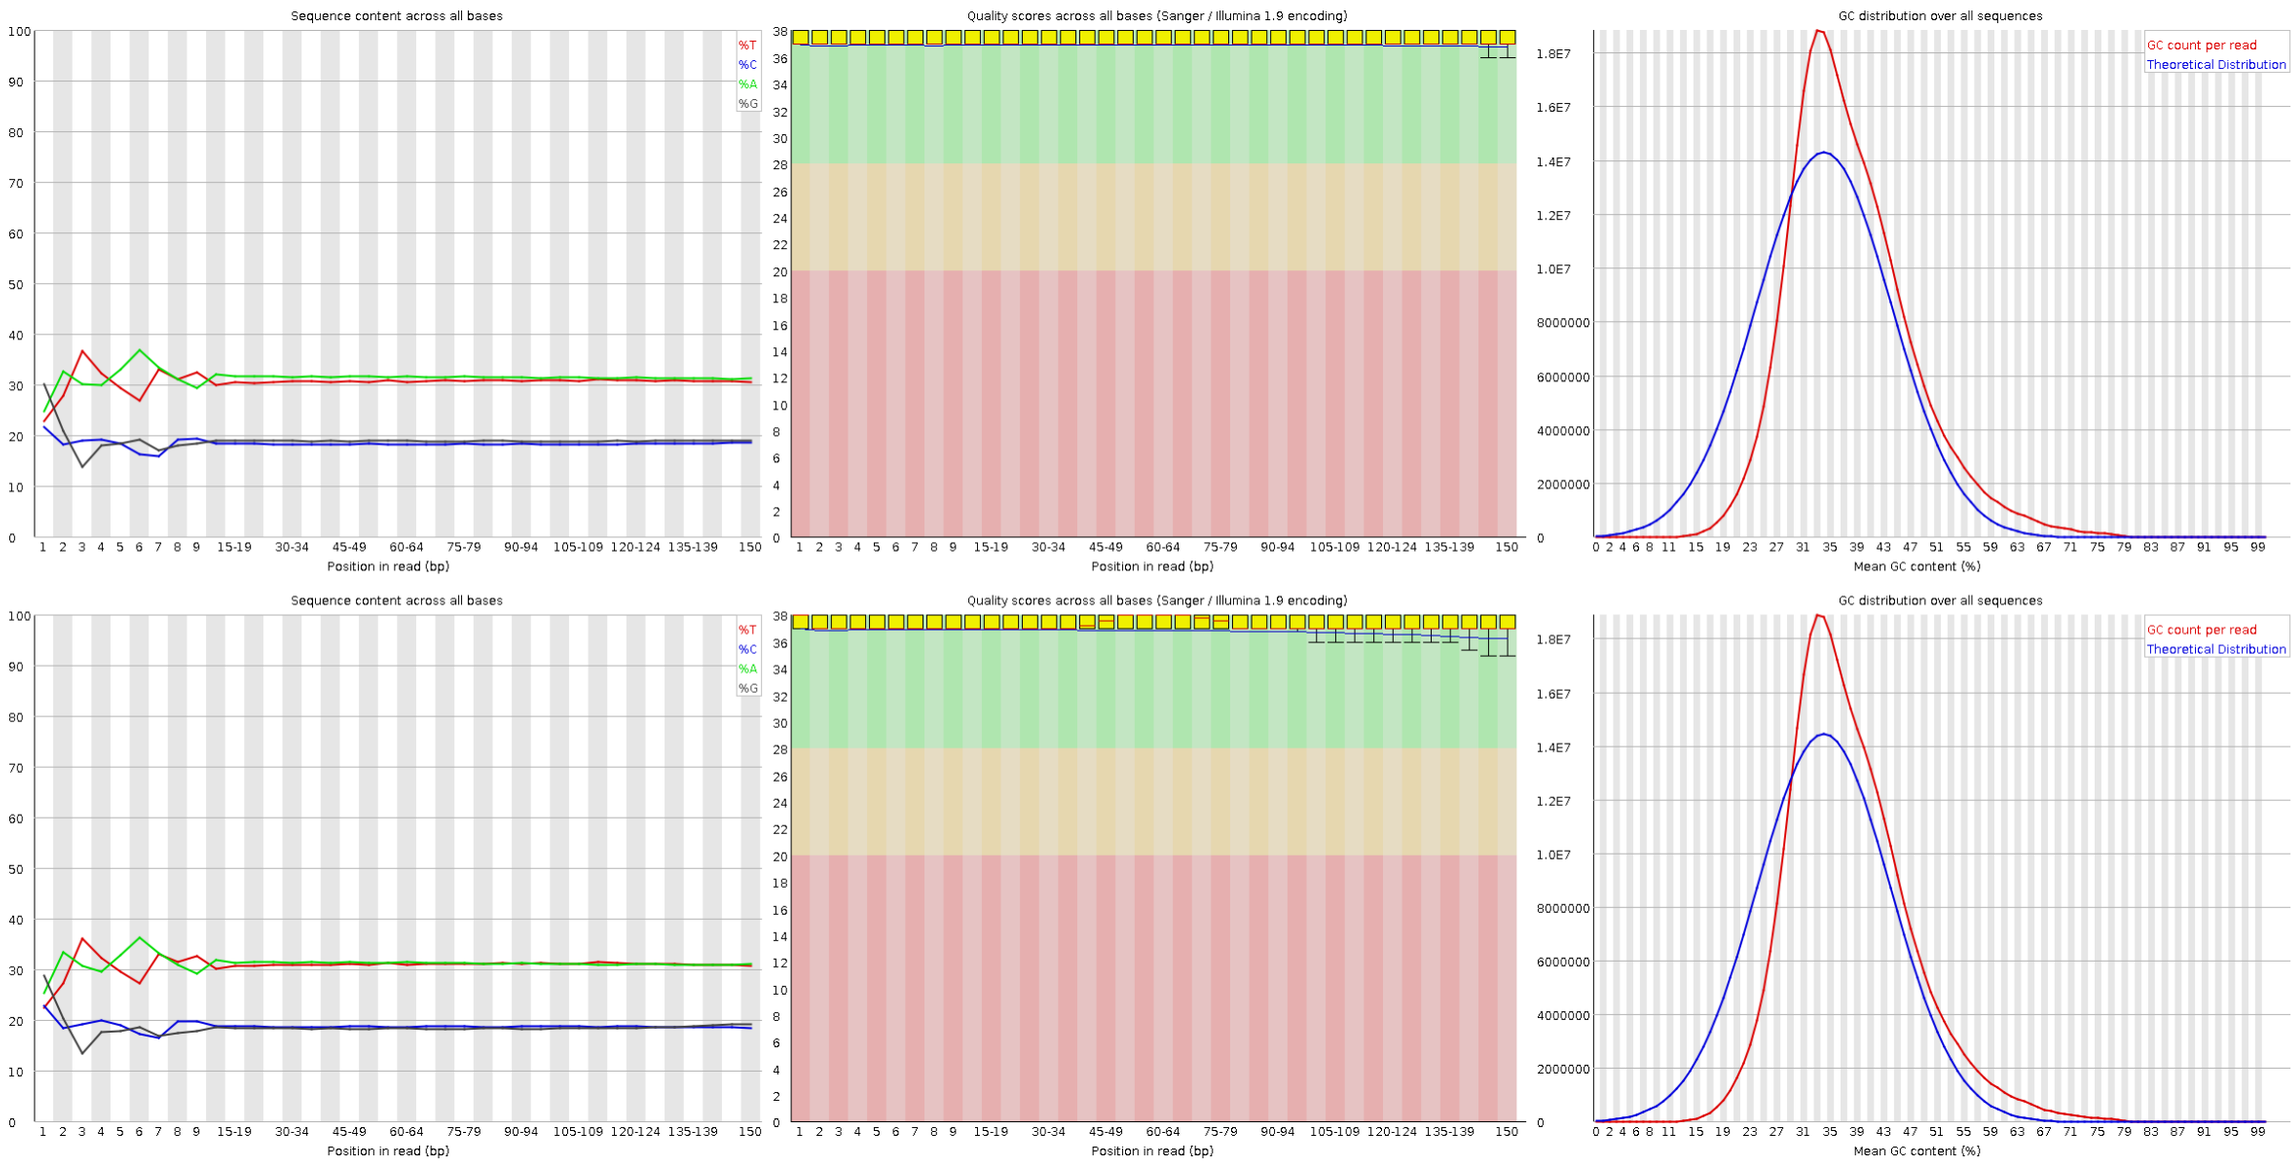

样本survey 的文库 *Nymphaea lotus* 测序结果质量

说明：

1. 左上、左下为Read1、Read2的测序碱基含量分布，在一定程度上可以反映测序是否正常。普通文库的DNA测序，根据碱基互补原则，理论上A与T和C与G的碱基含量基本相等。由于随机扩增引物扩增但引物种类有限而导致Reads前几位碱基的比例不均衡而出现波动，属于正常现象；
2. 中上、中下为Read1、Read2的测序质量分布，在一定程度上可以反映测序过程中测序质量的稳定性。测序数据的每一个碱基都有一个质量值与之对应，而测序错误率与碱基质量有关，受文库质量、测序试剂、测序仪等多种因素影响。根据测序技术的特点，测序片段末端的碱基质量一般会比前端的低；
3. 右上、右下为Read1、Read2的测序数据GC含量分布,样本基因组的GC含量会影响建库过程中PCR扩增的效率，因此测序过程对不同GC的测序片段存在一定的偏好性，但是测序结果的整体GC含量应该跟该物种全部表达基因的GC含量一致。

4.3.3 NT比对情况统计

对过滤后的高质量数据随机抽取10,000对Reads数据，通过Blast软件比对NCBI核苷酸数据库（NT库），将比对次数排名前五的物种展示出来。下面是各个文库NT比对的结果。

样本survey 的文库 *Nymphaea lotus* 数据NT库比对结果

Species	fq_1	fq_2	total(%)
Nymphaea_lotus	327	332	3.29
Nymphaea_colorata	49	45	0.47
Nymphaea_sp.	21	21	0.21
Nymphaea_odorata	15	16	0.15
Spyridium_parvifolium	5	6	0.06

从比对结果看，文库数据中不含有明显的外源污染。

4.4 质控小结

本次共构建1个*Nymphaea lotus*样本的300-500bp文库，测序所得clean data 108.14 Gb 数据，测序质量正常，测序错误率正常。NT库比对结果显示没有明显外源污染，建库测序成功。

5 K-mer分析

5.1 K-mer 分析原理

基因组在组装前，可以通过测序得到的序列估计其特征。我们采用基于K-mer 的分析方法来估计基因组大小和杂合率以及重复序列信息。

K-mer：即从一段连续序列中迭代地选取长度为K个碱基的序列，若每条序列的长度为L，那么可以得到L-K+1个K-mer。我们通常取K=17来进行分析。(针对长度为K的K-mer，对于 A,T,C,G四种碱基类型，一共能产生的K-mer种类数为4k个；因此，选择K=17，可以产生的K-mer 种类数为 417，由此可保证产生足够多的K-mer种类数去覆盖整个基因组。)

5.1.1 基因组大小预估

假设：

1）从每条序列中逐碱基取出的所有K-mer 能够遍历整个基因组。根据Lander_waterman算法，基因组大小（G）满足如下公式：

$$C_{base} = \frac{C_{k-mer} \times L}{L-K+1}$$

$$G = \frac{n_{k-mer}}{c_{k-mer}} = \frac{n_{base}}{c_{base}}$$

其中，n_{base}和$n_{K\text{-}mer}$为序列的碱基总数和K-mer数，C_{base}和$C_{K\text{-}mer}$为覆盖碱基的期望深度和K-mer期望覆盖深度。

2） K-mer的覆盖深度频率分布服从泊松分布。

$$P_{Kspecies}(x) = \frac{c^x}{x!} e^{-c}$$

公式中， c为峰值对应的测序K-mer深度，是K-mer深度的估计值。根据上述两个假设，从所有测序序列中逐碱基取K-mer，统计K-mer频数分布，计算获得K-mer深度分布曲线和深度乘积曲线。根据曲线获得K-mer深度估计值c，估计基因组大小。

K-mer分析适用于分析唯一主峰区域所占比例较大的基因组，当基因组杂合非常高或者重复序列比例非常大时，其影响可能导致无法通过K-mer分析正确估计基因组大小。

5.1.2 杂合率和重复序列预估

在理想数据模型中，一套基因组上每个K-mer应该只出现一次，不存在重复序列或者杂合的情况，即基因组上的所有K-mer的频数均为 1。而在实际样本中，由于杂合和重复序列的影响，每个K-mer对应的频数不确定。

我们可以根据出现的频率数（i）将K-mer分类，由此来计算每一类K-mer种类数的百分比$a_i=n_{i,Kspecies}/n_{Kspecies}$，个数的百分比$b_i=n_{i,Kindividuals}/n_{Kindividuals}$。考虑到基因组中K-mer频率数的分布为[1,m]，每类的期望深度为Ci=i*C，可以得到有杂合率和重复序列的基因组的 K-mer种类数的概率函数为：

$$P_{Kspecies}(x) = \sum_{i=1}^{m} a_i \times P_{Kspecies,i}(x)$$

有杂合率和重复序列的基因组的K-mer个数的概率函数为：

$$P_{Kindividuals}(x) = \sum_{i=1}^{m} b_i \times P_{Kindividuals,i}(x)$$

其中，$P_{Kspecies(x)}$表示期望深度为Ci的泊松分布， $P_{Kindividuals(x)}$表示期望深度为Ci的变形泊松分布。

对于杂合基因组来说，所有的K-mer可以分为两类：杂合K-mer和纯合K-mer。相对于整个二倍体基因组来说，杂合位点是散落在基因组中的。对于每一个杂合位点来说，有2*K个杂合K-mer覆盖，因此相比于纯合K-mer的期望深度，杂合K-mer的期望深度为C/2。在这种假设下，可通过其中$a_{1/2}$和 $n_{Kspecies}$估算杂合位点数以及基因组大小，并由以下公式(计算出杂合率。

$$\emptyset = \frac{a_{1/2} \times n_{Kspecies}/(2 \times K)}{n_{Kspecies} - a_{1/2} \times n_{Kspecies}/2} = \frac{a_{1/2}}{K(2-a_{1/2})}$$

其中a1/2为杂合K-mer种类数的百分比，$n_{Kspecies}$为所有K-mer的种类数。（此公式适于重复序列影响不大的基因组）。

另外，计算标准泊松分布和实际数据曲线峰值后的面积差值，也可得到重复序列百分比。因为测序错误或者测序层数会导致K-mer分布与泊松分布差异大，从而影响我们的估计值。在这里我们计算纯合峰深度1.8倍后面的K-mer个数所占的比例来估计重复序列比例。为了得到更准确的基因组特征的评估结果，还可以进一步结合其他已知物种的基因组信息横向比较。

5.2 K-mer 分析结果

通过GCE软件，对序列文件进行K-mer的计数和统计，预估基因组大小、杂合度和重复等信息。**详见：https://github.com/fanagislab/GCE/**

样本基因组特征统计情况（K-mer=17）

Sample	K-mer number	K-mer Depth	Genome Size(Mb)	Heterozygous Ratio (%)	Repeat (%)
Nymphaea_lotus	96605365576	55	1713.74	0.24	74.14

说明：

1. Sample：样本名称；
2. K-mer number：K-mer总数；
3. K-mer Depth：K-mer深度，即泊松分布对应的期望值；

4. Genome size：计算得到的基因组大小， K-mer number/K-mer Depth；
5. Heteozygous ratio：杂合率；
6. Repeat：K-mer分析得到的重复率，根据主峰后1.8倍的K-mer总数占所有K-mer数的百分比计算。（与生物学有功能的重复元件不同）。

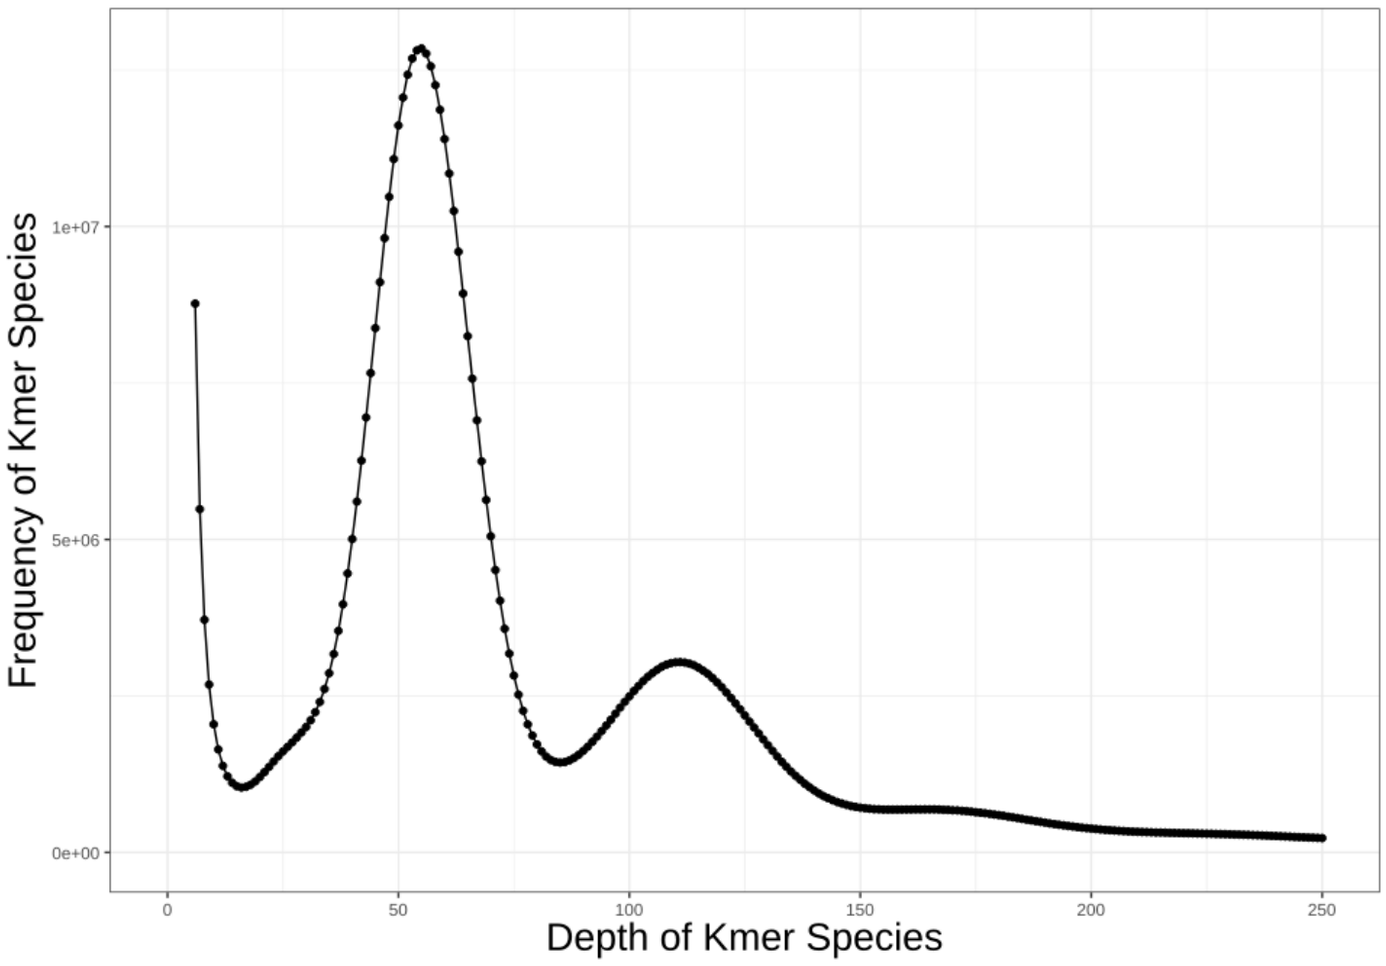

样本 K-mer种类数频率分布图

6 结论

对*Nymphaea lotus* 基因组的测序数据进行基因组survey分析，结果如下：

样本*Nymphaea lotus*：NT库比对结果显示，文库数据中应该不含有明显的外源污染。K-mer分析结果显示，样本基因组大小约为1713.74Mb，杂合率为0.24%，重复序列比例为74.14% ，基因组GC含量约为37.50% 。

7 软件版本

Analysis	Software	Version
数据质控	SOAPnuke	(v2.1.0)
数据质控统计	FastQC	(v0.11.7)
NT比对	BLASTN	(v2.7.1)
基因组survey评估	GCE	(v1.0.2)

8 参考文献

[1] Chen Y, Chen Y, Shi C, et al. SOAPnuke: a MapReduce acceleration-supported software for integrated quality control and preprocessing of high-throughput sequencing data. Gigascience. 2018;7(1):1-6.

[2] FastQC: https://github.com/s-andrews/FastQC/issues.

[3] Altschul SF, Gish W, Miller W, Myers EW, Lipman DJ. Basic local alignment search tool. J Mol Biol. 1990 Oct 5;215(3):403-10.

[4] Liu B , Shi Y , Yuan J , et al. Estimation of genomic characteristics by analyzing k-mer frequency in de novo genome projects[J]. Quantitative Biology, 2013, 35(s 1–3):62-67.